

Multi-TAP: Multi-criteria Target Adaptive Persona Modeling for Cross-domain Recommendation

Daehee Kang (UNIST) · Yeon-Chang Lee (UNIST)
KDD 2026 · arXiv:2603.07086

Presented by Minsung Park



0. Overview

비유	쿠팡 전자제품관(A)에서 산 기록으로 가구관(B)에서 추천을 해준다고 가정
기존 방법	A에서 "이 사람은 비싼 걸 좋아함"처럼 한 줄로 요약한 뒤 B로 통째로 전달
문제	같은 전자제품관 안에서도 컴퓨터는 비싼 걸, 이어폰은 싼 걸 사는 사람이 많음 → 한 줄로 요약하는 순간 이 차이가 뭉개짐
해결 (P1)	5개 기준별로 LLM이 페르소나를 문장으로 작성하고, 이를 벡터로 변환한 뒤 Attention으로 결합
해결 (P2)	A의 정보를 통째로 옮기지 않고, "도플갱어"라는 중간 다리를 거쳐 B에 맞는 정보만 흡수

핵심 질문의 전환 "선호를 어떻게 옮길까(How)?" → "어떤 선호를 옮길까(What)?"

1. Introduction — Background

CDR (Cross-domain Recommendation) : 데이터가 많은 source 도메인의 정보를 빌려와, 데이터가 부족한 target 도메인의 추천을 개선하는 분야

해결하려는 문제: data sparsity (데이터 희소성) · 예: Amazon, eBay처럼 여러 도메인을 가진 이커머스

접근	대표 연구	핵심 아이디어
A. 매핑 방식	EMCDR, SA-VAE	양쪽 도메인을 모두 쓴 사람(overlapping users)을 이용해, source 사용자 벡터를 target 벡터로 바꿔주는 함수를 학습
B. 분해 · 공유공간 방식	UniCDR, EDDA	취향을 "도메인 공통 취향(domain-shared)"과 "도메인 고유 취향(domain-specific)"으로 분리

공통 한계 두 방식 모두 도메인 단위로 사용자를 벡터 하나로 요약 → 맥락에 따라 달라지는 선호 신호가 압축됨

1. Introduction — Background


방법	접근	핵심 아이디어	Multi-TAP 관점의 한계
EMCDR	매핑	Source-Target 벡터를 따로 학습한 뒤, 겹치는 사용자로 번역 함수(선형/MLP) 학습	사용자를 도메인당 벡터 하나로 요약해 통째로 번역
SA-VAE	매핑	VAE로 두 도메인의 잠재 공간 자체를 정렬 (Rigid: 인코더 공유, Soft: Source를 닮도록 유도)	공간 전체를 맞추는 방식이라 여전히 도메인 단위 정렬
UniCDR	분해·공유공간	사용자 표현을 도메인 공유 벡터 + 도메인 고유 벡터로 나눠, 공유 부분으로 지식 전이	고유 부분도 도메인당 벡터 하나라 도메인 안의 카테고리 차이(IDH)는 미처리
EDDA	분해·공유공간	임베딩 수준까지 분리하고, 그래프 랜덤워크로 닮은 사용자/아이템 쌍을 찾아 정렬	컴퓨터는 비싸게, 이어폰은 싸게 사는 카테고리별 차이(IDH)가 그 한 벡터 안에서 뭉개짐

Multi-TAP 관점의 한계

네 방법 모두 사용자를 도메인 단위로 표현해, 도메인 안의 카테고리별 선호 차이(IDH)를 다루지 못합니다.

1. Introduction — Motivation

다른 카테고리로 이동할 때 상대적 가격 선호가 바뀐 사용자 비율 (Electronics 도메인, target 카테고리 평균)



기준 카테고리	고가 선호 사용자	저가 선호 사용자
Computer	60% shift	65% shift
Home Audio	54% shift	66% shift

- 기존 CDR의 가정: "한 도메인 안에서 취향은 균일하다" → 본 논문에서는 가정 자체가 틀렸다고 주장
- IDH (Intra-Domain Heterogeneity, 도메인 내 이질성): 같은 도메인 안에서도 카테고리마다 선호가 달라지는 현상
- IDH를 무시하면 전이 전에 이미 정보 손실 → 압축된 벡터를 옮기며 손실이 더 커짐 (indiscriminate transfer, 무차별 전이)

How to transfer?
기존: 선호를 어떻게 옮길까



What to transfer?
논문: 어떤 선호를 옮길까

1. Introduction — Contributions

1

Key Empirical Observation

CDR에서 도메인 내 이질성(IDH) 문제를 정의하고 실데이터로 정량 분석

2

Novel CDR Framework

Multi-criteria 페르소나 모델링으로 IDH를 포착하고, target-adaptive 도플갱어로 선택적 전이를 수행하는 Multi-TAP 제안

3

Extensive Experiments

Amazon 실데이터에서 5개 SOTA CDR 방법 대비 HR@5 최대 36.3% 향상

2. Motivation — IDH의 정의와 측정 (1)

정의 Ajzen의 계획행동이론: 사람의 행동은 하나의 고정된 선호에서 나오는 게 아닌, 맥락에 따라 달라지는 여러 잠재 의도에서 나옴

ex) 컴퓨터는 200만 원짜리를, 이어폰은 3만 원짜리를 산다 (도메인 단위로 한 번에 뭉뚱그리면 안 됨)

기준 3가지 가격(price) · 품질(평균 평점) · 인기(상호작용 수)

① 아이템 등급 매기기 (Eq.1)

카테고리마다 줄 세운 뒤 3등분(tertile) → 1(저) · 2(중) · 3(고)

$$\text{bin}_i^{(k)} = \begin{cases} 1, & x_i^{(k)} < Q_c^{(k)}(1/3) \\ 2, & Q_c^{(k)}(1/3) \leq x_i^{(k)} < Q_c^{(k)}(2/3) \\ 3, & x_i^{(k)} \geq Q_c^{(k)}(2/3) \end{cases}$$

- x : 아이템의 원래 값(가격 등), Q : 카테고리 내 분위수(1/3, 2/3 지점)
- 왜 카테고리별로? 노트북 50만원은 저가, 이어폰 50만원은 고가 → 스케일 정규화

② 사용자 점수 (Eq.2)

그 카테고리에서 이용한 아이템 등급의 평균

$$s_{u,c}^{(k)} = \frac{1}{|\mathcal{I}_{u,c}|} \sum_{i \in \mathcal{I}_{u,c}} \text{bin}_i^{(k)}$$

- 값이 크면 "이 카테고리에서는 비싼 걸 사는 사람"

Eq.(1)–(2), Kang & Lee, KDD 2026, Section 2

2. Motivation — IDH의 정의와 측정 (2)

③ 사용자 라벨

사용자 점수를 다시 3등분해 Low / Medium / High 라벨 부여 → 뒤에서 페르소나 DB에 그대로 재사용

④ 선호 보존율 (Eq.3)

카테고리 C_b 에서 라벨 g (예: High)였던 사람 중, 카테고리 C_t 에서도 g 인 사람의 비율


$$R_g^{(k)}(c_b \rightarrow c_t) = \frac{\sum_{u \in \mathcal{U}_{c_b, c_t}} \mathbf{1}[\ell_{u, c_b}^{(k)} = g \wedge \ell_{u, c_t}^{(k)} = g]}{\sum_{u \in \mathcal{U}_{c_b, c_t}} \mathbf{1}[\ell_{u, c_b}^{(k)} = g]}$$

- 분모: 두 카테고리를 모두 이용한 사용자 중 C_b 에서 g 인 사람
- 분자 : Target 카테고리 C_t 에서도 g 인 사람
- 비대칭: $A \rightarrow B$ 와 $B \rightarrow A$ 의 값이 다름 (분모가 다르기 때문)
- 값이 낮을수록 IDH가 강함

정의: A에서 High였던 사람 중 B에서도 High인 비율

Eq.(3), Kang & Lee, KDD 2026, Section 2

2. Motivation — Observations




- 전반적으로 보존율이 낮음(IDH 강함)
- Electronics의 Car → GPS는 약 31%
- 저가 선호 사용자가 고가 선호 사용자보다 보존율이 더 낮음
- 결론: 도메인 단위 벡터는 필연적으로 정보를 압축 → 전이 전에 기준별로 세밀하게 모델링해야 함

(a) Electronics · 가격 기준 (b) Sports · 인기 기준 위: High 유지 / 아래: Low 유지

Figure 2, Kang & Lee, KDD 2026 (p.3) · 다른 도메인 결과는 Figure 6 (Appendix B)

3.1 Overview



설정

- source 도메인, target 도메인, 두 도메인을 모두 이용한 overlapping users
- 목표: target 도메인 추천 정확도 향상 (특히 overlapping users)
- 아이템 메타데이터: 카테고리, 가격, 스토어 등

전체 흐름

(P1) source · target 각각에서 페르소나 벡터 생성

(P2) 도플갱어로 source 정보를 선별 전이

추천 target 아이템과 매칭

Figure 3, Kang & Lee, KDD 2026 (p.4)

3.2 (P1) Step 1: User Persona Database

P1은 source와 target에서 각각 독립적으로 수행 · 사용자 선호를 5개 기준으로 분해

기준	의미	측정 대상	출처
PS 가격 민감도	비싼 걸 사는가	아이템 가격	Section 2의 라벨 재사용
QP 품질 선호	평점 높은 걸 사는가	평균 평점	Section 2의 라벨 재사용
PB 인기 편향	인기 있는 걸 사는가	상호작용 수	Section 2의 라벨 재사용
CD 카테고리 다양성	얼마나 넓게 사는가	이용한 카테고리 수	새로 정의
CF 카테고리 친숙도	한 카테고리를 얼마나 깊게 사는가	카테고리 내 상호작용 수	새로 정의

아이템 속성만으로는 사용자가 넓게 탐색하는지 한 곳을 깊게 이용하는지 알 수 없기 때문에 뒤의 두 기준을 추가

왜 이 5개인가? 가격 · 평점 · 카테고리는 어느 이커머스에나 있는 메타데이터 → 추가 피처나 수작업 없이 다른 도메인으로 일반화 가능

3.2 (P1) Step 1: Category Diversity · Familiarity · Persona DB

CD 카테고리 다양성 (Eq.4–5)

한 도메인에서 이용한 서로 다른 카테고리의 수

$$x_{u,d} = |\{c(i): i \in \mathcal{I}_{u,d}\}|$$

- 전체 사용자 대비 3등분 → Low / Medium / High
- 도메인당 값이 1개 (카테고리별로 따로 없음)

CF 카테고리 친숙도 (Eq.6–7)

카테고리 내 상호작용 수를 같은 카테고리 이용자와 비교해 3등분

$$Q_c(q) = \text{Quantile}_q(|\mathcal{E}_{u,c}|: u \in \mathcal{U}_c), \quad q \in \{1/3, 2/3\}$$

- 카테고리별로 계산하는 이유: 카테고리마다 원래 구매 빈도가 다름 (소모품은 자주, 가구는 드물게)

Eq.(4)–(8), Table 8 (Appendix A.1, p.11), Kang & Lee, KDD 2026

Persona DB (Eq.8)

카테고리 × 기준 조합마다 라벨을 모아둔 표

$$\mathcal{D}_{u,d} = \left\{ \ell_{u,c}^{(k)} \right\}_{k \in \mathcal{K}, c \in \mathcal{C}_d}$$

User persona database (e.g., Home)

```
[
{ "User ID": "AEXXX",
  "price_affiliated_group": {
    "Kitchen & Dining": "L", "Vacuums & Floor Care": "L",
    "Storage & Organization": "H", "Home Décor Products": "M",
    "rating_score_preferred_group": {
      "Kitchen & Dining": "M", "Home Décor Products": "H",
      "Bedding": "M", "Vacuums & Floor Care": "H",
      "Storage & Organization": "H" },
    "rating_nums_preferred_group": {
      "Kitchen & Dining": "L", "Home Décor Products": "H",
      "Bedding": "L", "Vacuums & Floor Care": "L", "Storage & Organization": "M"},
    "cats_familiarity": {
      "Bedding": "L", "Home Décor Products": "H",
      "Kitchen & Dining": "L",
      "Storage & Organization": "L", "Vacuums & Floor Care": "L" },
    "cats_interaction_diversity": "L" },
{ "User ID": "AGXXX",
  "price_affiliated_group": {
    "Kitchen & Dining": "H", "Vacuums & Floor Care": "L",
    "Furniture": "H", "Bedding": "L", "Storage & Organization": "H" },
... }
]
```

3.2 (P1) Step 2: Persona Construction with LLM

핵심 LLM은 "추론기"가 아니라 "번역기" — 숨은 취향을 추측하지 않고, 계산된 통계를 문장으로만 옮김

이유 길고 비정형적인 입력은 LLM의 추론 성능을 떨어뜨리고 환각(hallucination)을 늘림

입력 3개 + 고정 프롬프트

- 도메인 설명: 인기 아이tem 50개 + 고평점 아이tem 50개의 메타데이터로 만든 요약 (Appendix A.2)
- 대표 메타데이터: 사용자가 이용한 아이tem의 제목 · 카테고리
- Step 1의 Persona DB
- 기준별 의미를 정해둔 고정 프롬프트 → 기준끼리 뜻이 섞이는 것(semantic drift) 방지


$$f_u^{(k)} = \left[\text{LLM} \left(\mathcal{T}_d^{\text{desc}} \parallel m_{u,d} \parallel \left[p^{\text{sona}} \parallel \mathcal{D}_{u,d}^{(k)} \right] \right) \right]_k$$

출력 기준별 3-4문장 페르소나 5개를 JSON으로, 한 번의 호출로 생성 · 분포 수준 요약이라 자주 재생성할 필요 없음

Eq.(9), Table 2 (p.5), Kang & Lee, KDD 2026

Component	Content
Task Description	You are an e-commerce user analysis expert. Analyze the provided context (Domain, User ID, USER SPECIFIC INPUTS, and History) to generate FIVE natural-language personas, each focusing on: 1. Price sensitivity, 2. Quality preference, 3. Popularity bias, 4. Category familiarity, 5. Category diversity.
Input Format	<pre>{ "Domain": "<domain_name>", "Domain description": "<domain_desc>", "User ID": "<user_id>", "category_price_level": { "catA": "H M L", { "catB": "H M L", ..., { "catX": "H M L" } "category_rating_level": { "catA": "H M L", { "catB": "H M L", ..., { "catX": "H M L" } "category_popularity_level": { "catA": "H M L", { "catB": "H M L", ..., { "catX": "H M L" } "category_familiarity_level": { "catA": "H M L", { "catB": "H M L", ..., { "catX": "H M L" } "overall_category_diversity": "H M L", "History": [{ "item_id": "...", "title": "...", "category": "...", "average_rating": n, "rating_number": n, "user_rating": n, "cat_item_price_tag": "H M L" }] }</pre>
Generation Rules	• Produce FIVE USER PERSONA in 3-4 sentences (at least 3). • Use USER SPECIFIC INPUTS then history. • Map levels to: H=High, M=Medium L=Low signal in <category>. <NOTIONS of USER SPECIFIC INPUTS> • category_price: Price class by category of items interacted with. • category_rating: Average rating level of items within each category. • category_popularity: Item popularity (review count) per category. • category_familiarity: Interaction frequency within each category. • category_diversity: Number of different categories explored overall.
Output Format	<pre>{ "User ID": "<user_id>", "Profiles": { "price_sensitivity": { "persona": "...", }, "quality_preference": { "persona": "...", }, "popularity_bias": { "persona": "...", }, "category_familiarity": { "persona": "...", }, "category_diversity": { "persona": "...", } }</pre>

3.2 (P1) Step 3: Persona Encoding and Aggregation



- 5개 문장을 각각 text-embedding-3-large로 벡터화 — 문장을 만든 LLM과 같은 계열 → 의미 일관성
- Self-attention으로 결합: 학습 가능한 MASK 토큰 = query, 5개 페르소나 벡터 = key · value

$$\alpha_u^{(k)} = \frac{\exp(\mathbf{e}_u^{\text{MASK}} \cdot \mathbf{e}_u^{(k)} / \sqrt{n})}{\sum_{k' \in \mathcal{K}} \exp(\mathbf{e}_u^{\text{MASK}} \cdot \mathbf{e}_u^{(k')} / \sqrt{n})}$$

$$\mathbf{h}_u = \text{Proj} \left(\text{FFN} \left(\sum_{k \in \mathcal{K}} \alpha_u^{(k)} \mathbf{e}_u^{(k)} \right) \right)$$

결과 source · target 페르소나 벡터가 하나씩

$\mathbf{h}_{u_s}, \mathbf{h}_{u_t}$

비유 심사위원(MASK)이 보고서 5개를 읽고 "이 사람은 가격 페르소나가 중요하네" 하며 가중치를 매기는 것 · $\sqrt{n}$ 은 값이 너무 커지지 않게 하는 스케일링

Figure 3(a) (p.4), Eq.(10)–(11), Kang & Lee, KDD 2026

3.3 (P2) Step 1: Doppelganger Generation

기존 방식의 문제 : contrastive 방법이 source 벡터와 target 벡터를 직접 가깝게 당김 → target 고유의 취향이 묻개짐
 => Direct Source-target alignment가 도메인 고유 선호를 압축하고 target 표현을 왜곡

해결 target을 기준점(anchor)으로 삼고, 학습도 target 도메인에서만 수행

- 초기값: target 페르소나를 그대로 복사 → target 중심에서 출발
- Cross-attention: query = target의 나, key · value = source의 나

$$\alpha_{u,s}^{dpl} = \frac{\exp(\tilde{\mathbf{h}}_{u_t} \cdot \mathbf{h}_{u_s} / \sqrt{n})}{\sum_{u' \in \mathcal{U}_s} \exp(\tilde{\mathbf{h}}_{u_t} \cdot \mathbf{h}_{u'_s} / \sqrt{n})}, \quad \tilde{\mathbf{h}}_{u_t} = \alpha_{u,s}^{dpl} \mathbf{h}_{u_s}$$
- 분모는 모든 source 사용자에게 대한 합 → 가중치 = "target의 내가, 여러 source 사용자 중 source의 나와 상대적으로 얼마나 닮았나" (0~1 사이의 숫자 하나)
- 도플갱어 = 가중치 × source의 나 → 닮은 만큼만 source 정보를 가져옴

	기존 contrastive	Multi-TAP
Anchor	target의 나	target의 나
Positive	source의 나 (직접)	나의 도플갱어 (간접)
Negative	다른 사람들의 source 벡터	다른 사람들의 도플갱어
효과	source로 강하게 끌려감	닮은 만큼만 source 정보를 받음

Eq.(12), Kang & Lee, KDD 2026

3.3 (P2) Step 2: Doppelganger-based Knowledge Transfer

target의 나는 내 도플갱어와는 가깝게, 다른 사람의 도플갱어와는 멀게 학습 (InfoNCE, Eq.13)

$$\mathcal{L}_{\text{dpl}} = - \sum_{u \in \mathcal{U}_o} \log \frac{\exp(\text{sim}(\mathbf{h}_{u_t}, \tilde{\mathbf{h}}_{u_t})/\tau)}{\sum_{u' \in \mathcal{U}_o} \exp(\text{sim}(\mathbf{h}_{u_t}, \tilde{\mathbf{h}}_{u'})/\tau)}$$

- sim: 코사인 유사도
- τ (온도): 작을수록 구분을 더 엄격하게
- 합은 overlapping users에 대해 계산

효과 source 정보가 "간접적으로" 유입 — source와 target을 직접 맞붙이지 않음 · 추천 손실과 함께 공동 최적화

비유 통역사(도플갱어)를 사이에 두는 셈 — source가 하는 말을 그대로 옮겨 적는 게 아니라, target 입장에 맞는 만큼만 전달받는 구조

Eq.(13), Kang & Lee, KDD 2026

3.4 Training Process

문제 페르소나(의미 정보)만으로는 "나랑 비슷한 사람이 산 것" 같은 협업 신호를 잡지 못함

해결 LightGCN(사용자-아이템 그래프에서 이웃 정보를 퍼뜨린 벡터)으로 미리 학습한 ID 벡터를 결합

$$\mathbf{z}_u = \text{MLP}([\mathbf{h}_{u_t} \parallel \mathbf{v}_{u_t}]), \quad \mathbf{z}_i = \text{MLP}([\mathbf{h}_{i_t} \parallel \mathbf{v}_{i_t}])$$

아이템 의미 벡터: 제목 · 카테고리를 같은 인코더로 벡터화 (512차원) · MLP는 단층

추천 손실: BPR (Eq.15)

산 아이템의 점수가 안 산 아이템의 점수보다 높도록 학습

$$\mathcal{L}_{\text{rec}} = - \sum_{(u,i,i')} \log \sigma(\hat{y}_{u,i} - \hat{y}_{u,i'}) + \lambda_{\theta} \|\theta\|^2, \quad \hat{y}_{u,i} = \mathbf{z}_u \cdot \mathbf{z}_i$$

최종 손실 (Eq.16)

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda \mathcal{L}_{\text{dpl}}$$

source 쪽은 미리 따로 학습 같은 BPR로 학습 후 target 학습 중에는 업데이트하지 않음 · 도메인 쌍이 정해지면 한번만, 사전학습 모델이 있으면 재사용 가능

Eq.(14)–(16), Kang & Lee, KDD 2026, Section 3.4

4. Evaluation — Questions & Datasets

Evaluation Questions

- EQ1 전체 성능
- EQ2 페르소나 모델링의 효과
- EQ3 도플갱어 전이의 효과
- EQ4 하이퍼파라미터 민감도
- EQ5 효율성

데이터 Amazon Reviews 2023 · 5개 도메인(Elec, Home, Sports, Cloth, Toys) · 가능한 10쌍 전부 실험 · 본문은 overlapping user가 가장 많은 3쌍

도메인 쌍	Overlapping users	나머지 쌍
Elec – Home	7,274	Appendix Table 12
Sports – Cloth	4,588	
Home – Toys	5,798	

시간 기준 분할 (Time-aware split)

- 2019년 이전 = 학습, 2019년 이후 = 검증 / 테스트 (두 기간에 모두 등장한 사용자만)
- 이유: 미래 정보가 학습에 새지 않게, 실제 서비스 상황과 비슷하게

Kang & Lee, KDD 2026, Section 4.1, Table 3

4. Evaluation — Protocol & Implementation

Full ranking 평가 후보를 샘플링하지 않고, 안 본 모든 아이템을 후보로 둠 → 어려운 설정이라 수치가 1~4% 수준

지표

- HR@5: 정답 아이템이 상위 5개 안에 들었는지
- NDCG@5: 정답이 위에 있을수록 점수를 더 줌
- 모든 결과는 seed 5개의 평균

$$\text{DCG@5} = \sum_{r=1}^5 \frac{\text{rel}_r}{\log_2(r+1)}, \quad \text{NDCG@5} = \frac{\text{DCG@5}}{\text{IDCG@5}}$$

Baselines

구분	방법
단일 도메인	BPRMF, NGCF, LightGCN
CDR	UniCDR, CDIME, CUT, PPA (가장 강한 경쟁자), DGCDR

구현 세부

- Adam, 최대 100 epoch + early stopping, batch 1024, 임베딩 128차원, GPU RTX 6000 Ada
- 페르소나 생성: gpt-4o, 사용자당 최근 30개 상호작용, 사용자당 약 \$0.022 · temperature 0.7 (도메인 설명 1.0)

Kang & Lee, KDD 2026, Section 4.1

4. EQ1 — Overall Performance

Source→Target	@5	BPR-MF	NGCF	Light-GCN	Uni-CDR	CDIMF	CUT	PPA	DG-CDR	Multi-TAP
Elec→Home	HR	1.69	1.66	1.77	1.69	1.94	1.96	3.06	2.63	3.23
	NDCG	0.49	0.49	0.51	0.54	0.57	0.58	0.89	0.76	0.91
Home→Elec	HR	1.66	1.48	2.21	1.55	1.64	1.57	1.79	1.57	2.44
	NDCG	0.47	0.42	0.63	0.47	0.46	0.46	0.54	0.47	0.77
Sports→Cloth	HR	1.56	1.51	1.66	1.71	2.21	2.96	3.36	2.25	4.09
	NDCG	0.42	0.42	0.46	0.47	0.68	0.92	0.98	0.63	1.11
Cloth→Sports	HR	1.59	1.82	2.20	1.37	1.37	1.67	2.25	1.85	2.08
	NDCG	0.50	0.56	0.72	0.42	0.39	0.51	0.71	0.58	0.68
Home→Toys	HR	0.95	0.84	0.96	0.91	1.31	1.23	1.35	1.19	1.56
	NDCG	0.27	0.23	0.25	0.27	0.41	0.37	0.36	0.30	0.47
Toys→Home	HR	1.44	0.88	1.75	1.85	1.55	2.13	2.98	2.73	3.11
	NDCG	0.40	0.23	0.47	0.51	0.43	0.58	0.80	0.73	0.88

6개 방향 중 5개에서 1위

Home → Elec

HR 2.44 vs PPA 1.79 → +36.3%

NDCG 0.77 vs 0.54 → +42.6%

예외: Cloth → Sports

PPA 2.25 > Light GCN 2.20 > Multi-TAP 2.08 (3위) · 반대 방향 Sports→Cloth에서는 4.09 vs 3.36으로 크게 앞섬

PPA: "이 사람 안에 취향 유형이 K개 있을 거야"라고 정해두고 데이터에서 **알아서** 찾게 해요. 그래서 각 유형이 뭘 뜻하는지 해석이 안 되고, K도 사람이 정해줘야 하고, target에 맞춘 조정도 없어요.

Multi-TAP: 가격, 품질, 인기, 다양성, 친숙도처럼 **이름 붙은 5개 기준**을 명시적으로 써요. 전이할 때도 target 기준으로 골라 받습니다.

4. EQ2 — Effectiveness of Persona Modeling

EQ2-1 페르소나 분해 (Table 5)

- Single (Raw): 페르소나 1개, 원래 값(가격 숫자 등)
- Single (Proc.): 페르소나 1개, 등급 라벨
- Multi (Proc.): 페르소나 5개, 등급 라벨 (제안 방법)

HR@5	Single (Raw)	Single (Proc.)	Multi (Proc.)
Sports→Cloth	3.70	3.77	4.09
Cloth→Sports	1.83	1.99	2.08

- 절대값보다 상대 등급이 더 좋은 신호
- 같은 입력이라도 분해하면 추가 이득

EQ2-2 결합 방식 (Table 6)

- Mean: 균등 평균
- Concat: 이어붙이기
- Self-Attn: 적응적 가중치 (제안 방법)

HR@5	Mean	Concat	Self-Attn
Sports→Cloth	3.66	3.99	4.09
Cloth→Sports	1.93	2.01	2.08

- 사용자 · 도메인마다 중요한 기준이 다름 → 적응적 가중치가 중요

Table 5, Table 6, Kang & Lee, KDD 2026 (p.8)

4. EQ2-3 — Cold-start Scenario

설정 사용자의 10%를 뽑아 target 학습 데이터의 상호작용을 5개 미만으로 제한

Source→Target	HR@5 PPA	HR@5 Multi-TAP	NDCG@5 PPA	NDCG@5 Multi-TAP
Elec→Home	3.25	3.19	0.80	0.82
Home→Elec	2.31	2.42	0.69	0.75
Home→Toys	1.24	1.42	0.31	0.39
Toys→Home	2.26	2.20	0.53	0.55

PPA 대비 최대 향상

HR +14.52%

Home→Toys, 1.42 vs 1.24

NDCG +25.81%

Home→Toys, 0.39 vs 0.31


정확한 해석

- NDCG@5는 4개 방향 모두 우세, HR@5는 Elec→Home(3.25 vs 3.19), Toys→Home(2.26 vs 2.20)에서 PPA가 근소하게 높음
- 분해된 페르소나 표현이 희소한 상호작용 조건에서도 더욱 강건한 도메인 간 선호도 전이를 가능하게 함을 시사한다.

Table 7, Kang & Lee, KDD 2026 (p.8)


4. EQ3 · EQ4 · EQ5

EQ3 도플갱어 전이의 효과 (Figure 4)



- Direct-ID: LightGCN ID 벡터끼리 직접 정렬
- Direct-Persona: 페르소나 벡터끼리 직접 정렬
- Direct-Both: 둘을 이어붙인 것끼리 직접 정렬 (백본 동일, 전이 방식만 다름)
- Multi-TAP이 모든 경우 최고, 직접 정렬은 방향마다 불안정 → 도메인 고유 신호를 억누를 수 있음

EQ4 하이퍼파라미터 민감도 (Figure 5)



- λ (도플갱어 손실 가중치): 0이 아니면 항상, 1보다 클 때 특히 좋음 → 의미적 지식 전이가 중요
- τ (온도): 0.4~0.6에서 최적, 도메인 쌍이 달라도 안정적

EQ5 효율성 학습 9~30분 (LightGCN 위에 가벼운 모듈만) · 페르소나 생성 사용자당 약 3초, 오프라인

Figure 4 (p.9, 좌측 단), Figure 5 (p.9, 우측 단), Kang & Lee, KDD 2026

5. Related Work

분류	대표 연구	한계
매핑 방식	EMCDR, CDIMF	모두 도메인 단위로 작동 → IDH를 다루지 않음
분해 방식	UniCDR, EDDA	
부정적 전이 완화	CUT, TrineCDR, DGCDR	

PPA와의 차이

- PPA도 여러 선호 "프로토타입"을 쓰지만 상호작용 데이터에서 암묵적으로 학습
- 프로토타입 개수를 하이퍼파라미터로 정해야 함
- target 도메인에 맞춰 조정되지 않음

LASSO (LLM 기반)와의 차이

- LLM이 알아서 추론해 비정형 프로필 1개로 압축
- 제어가 어렵고 전이가 불안정할 수 있음

Multi-TAP 명시적이고 해석 가능한 5개 기준 + 구조화된 입력으로 LLM 역할 제한 + target 적응형 전이

6. Conclusion

관찰	기존 CDR은 도메인 내 이질성(IDH)을 명시적으로 포착하지 못함 — 한 도메인 안에서도 선호는 카테고리마다 다름
방법	다중 페르소나로 이질적 선호를 구조화해 모델링하고(P1), 도플갱어 정렬로 target 적응적 전이를 수행(P2)
결과	SOTA 대비 성능 우위, 동시에 계산 효율적

7. Limitations

검증 범위 Amazon 데이터에서만 검증되어서 타 데이터셋에서도 이런 우수한 성능을 보이는지 추가 검증이 필요해 보인다

표본 수 표본이 적은 카테고리에서는 영향이 생길 수 있음. 상품이 3~4개뿐이면 극단값 하나가 기준선 위치를 바꿀 수 있다.

시간 변화 페르소나는 시간이 지남에 따라 변함