MARIO: Modality-Aware Attention and Modality-Preserving Decoders for Multimedia Recommendation

Taeri Kim · Yeon-Chang Lee · Kijung Shin · Sang-Wook Kim
Hanyang University · KAIST
CIKM 2022 · DOI 10.1145/3511808.3557387

Presented by Minsung Park



UNIST

FIRST IN CHANGE

0. Overview

비유	상품 하나를 디자인(이미지)·스펙(텍스트)·판매기록(상호작용) 세 전문가가 함께 평가한다고 가정
기존 방법	"우리 손님은 디자인을 70% 본다"처럼 모든 사람(LATTICE) 또는 사람마다(GRCN) 비율을 하나로 고정
문제 (1)	같은 사람도 아이폰은 스펙, 에어팟은 디자인 때문에 삼 → (사용자, 상품) 쌍마다 모달리티의 영향력이 다름
문제 (2)	학습이 상품 임베딩을 "산 사람들의 평균 취향" 쪽으로 끌고 감 → 이미지·텍스트만 아는 고유 정보가 지워짐
해결 (C2)	Modality-aware Attention: 쌍마다 세 모달리티에 서로 다른 가중치를 줘서 결합
해결 (C3)	Modality-preserving Decoder: 압축한 임베딩으로 원래 특징을 복원하게 해 고유 정보를 붙잡아 둠

핵심 질문의 전환 "모달리티를 어떻게 섞을까?" → "고유 정보는 지키면서, 쌍마다 다르게 섞으려면?"

1. Introduction — Background

Multimedia Recommendation : 구매·클릭 기록(상호작용)에 더해 상품의 이미지·텍스트 같은 멀티모달 특징(multimodal 함께 써서 추천하는 분야

CF (Collaborative Filtering) : "나와 취향이 비슷한 사람이 산 물건"을 추천 · 기록만 쓰므로 기록이 적은 상품은 잘 이해하지 못함

해결하려는 문제: data sparsity (데이터 희소성) · 실험 데이터 4종 모두 사용자–상품 표의 99% 이상이 빈칸

접근	대표 연구	핵심 아이디어
A. 단일 모달리티	VBPR, CTRank	이미지(CNN 특징) 또는 텍스트(LDA 토픽) 하나만 CF에 결합
B. 다중 모달리티	JRL, MAML, MMGCN, GRCN, LATTICE	이미지·텍스트·상호작용을 함께 써서 사용자·상품 임베딩 학습

공통 한계 B 방식도 ① 모달리티 영향력을 전역·사용자 단위로만 보고 ② 학습 중 모달리티 고유 정보를 잃어버림

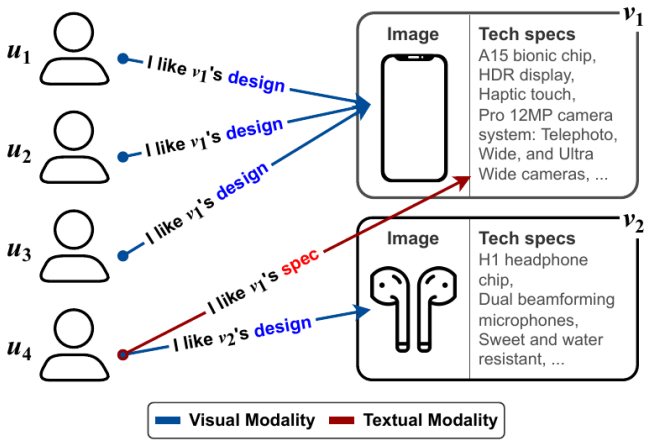
Section 1–2, Kim et al., CIKM 2022

1. Introduction — Background

방법	접근	핵심 아이디어	MARIO 관점의 한계
MAML	거리 기반	사용자 임베딩과 이미지·텍스트 상품 임베딩을 유클리드 공간에서 결합해 선호 예측	모달리티별 영향력을 쌍 단위로 나눠 보지 않음
MMGCN	그래프 · 이른 융합	모달리티마다 사용자–상품 그래프를 만들고 GCN 으로 모달리티별 선호를 학습한 뒤 합산	이미지·텍스트 학습에 상호작용이 처음부터 섞임 → 고유 정보 손실 최대
GRCN	그래프 정제	모달리티별 선호로 사용자–상품 그래프의 잡음 연결을 제거한 뒤 GCN 적용	영향력이 사용자 단위(User-level) → 한 사람은 늘 같은 비율
LATTICE	상품–상품 그래프	모달리티 유사도로 상품 간 숨은 관계(kNN 그래프)를 학습해 상품 임베딩 보강	영향력이 전역(Global) · **인기 상품의 고유 정보 손실이 큼**

MARIO 관점의 한계 네 방법 모두 쌍(Interaction) 단위 영향력을 보지 않고, 학습된 상품 임베딩에 모달리티 고유 정보를 보존하는 장치가 없음

1. Introduction — Motivation



방법	영향력 단위	비유
LATTICE	전역 (Global)	"우리 손님은 다 디자인파"
GRCN	사용자 (User)	"u4는 항상 스펙파"
MARIO	상호작용 (Interaction)	"u4는 아이폰은 스펙, 에어팟은 디자인"

- u1·u2·u3은 아이폰(v1)을 디자인 때문에, u4는 스펙 때문에 구매
- 그런데 u4가 에어팟(v2)을 산 이유는 디자인 → 같은 사람도 상품 상품마다 선택 이유가 다름
- 기존 가정 "모달리티 영향력은 전체(또는 사람마다) 하나" → 논문은 쌍마다 달라진다고 주장
- 또 하나의 문제: 사전학습 특징에는 상호작용으로 알 수 없는 정 정보(modality-specific properties)가 있는데, 기존 학습은 이를 최 를 최종 임베딩에서 잃어버림

어떻게 섞을까?
기존: 전체 비율로 섞기

代

지키면서 쌍마다 섞기
논문: 고유 정보 보존 +쌍 단위

Figure 1, Kim et al., CIKM 2022 (p.1)

1. Introduction — Contributions

1

Key Empirical Observation

기존 멀티미디어 추천이 ①쌍 단위 영향력을 무시하고 ②학습 중 모달리티 고유 특성을 잃는다는 점을 실험으로 처음 지

2

General Framework

Modality-aware Attention + Modality-preserving Decoder 기반 MARIO 제안 · 어떤 CF 모델에도 플러그인처럼 장착 가능

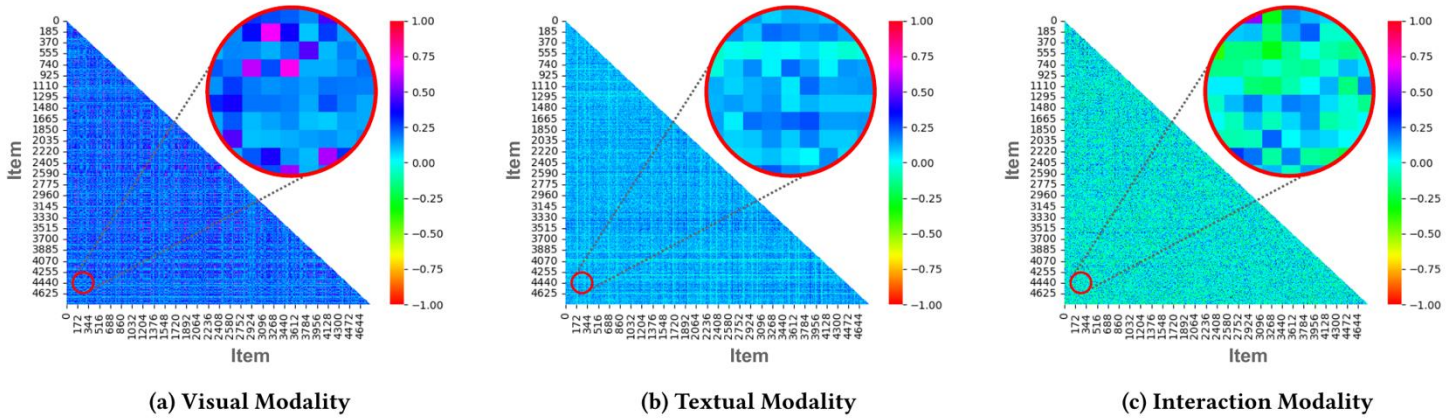
3

Extensive Experiments

Amazon 4개 데이터셋에서 7개 경쟁 모델 대비 우수 · 최강 경쟁자 대비 NDCG@10 최대 14.61% 향상

2. Motivation — 모달리티마다 "닮음"의 기준이 다르다

실험 Amazon-Men Clothing의 모든 상품 쌍에 대해 모달리티별 코사인 유사도 계산 (이미지: deep CNN · 텍스트: Sentence-Transformer · 상호작용 : LightGCN)



(a) Visual Modality (b) Textual Modality (c) Interaction Modality

모달리티 간 유사도의
피어슨 상관계수

ĭ ŏĭ ŭ V̆ĭ ◦ŭŭ

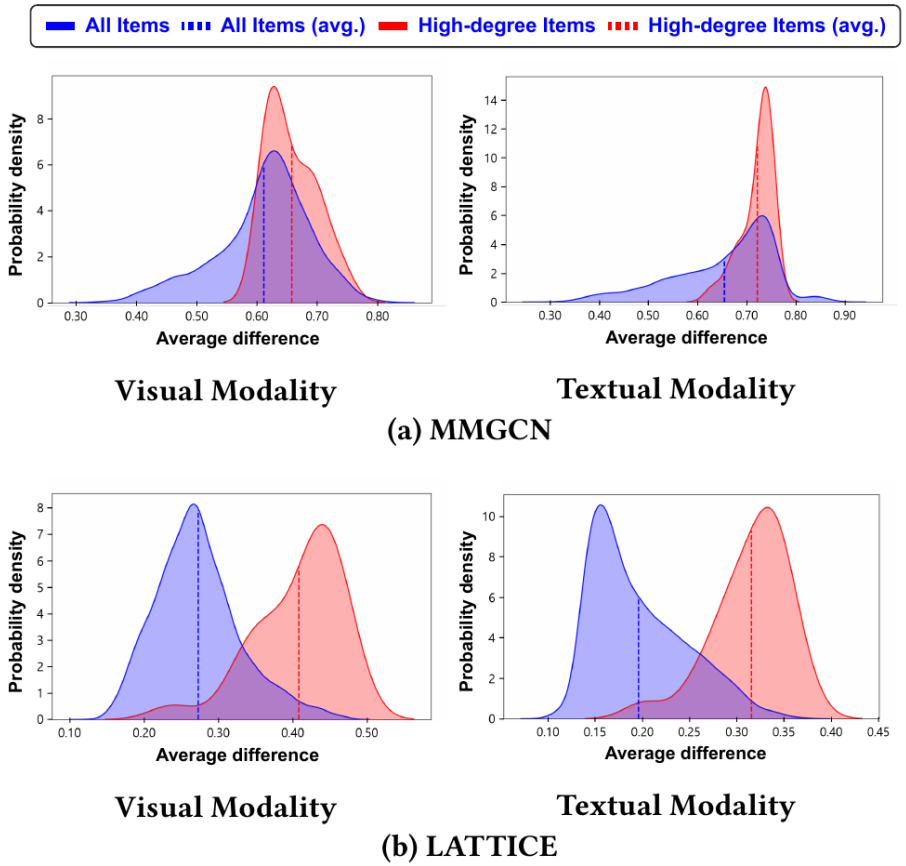
0에 가까울수록 "함께 움직이지 않음"

$$\cos(\mathbf{a},\mathbf{b}) = \frac{\mathbf{a}\cdot\mathbf{b}}{\|\mathbf{a}\|\|\mathbf{b}\|}$$

- 코사인 유사도: 두 벡터의 방향이 얼마나 같은지 (−1 ~ 1)
- 같은 상품 쌍이라도 모달리티마다 유사도가 크게 다름 (빨간 원 확대 부분)
- 결론: 상호작용만으로는 잡을 수 없는 모달리티 고유 특성이 존재

Figure 2, Section 3, Kim et al., CIKM 2022 (p.3)

2. Motivation — 학습이 끝나면 고유 정보가 사라진다



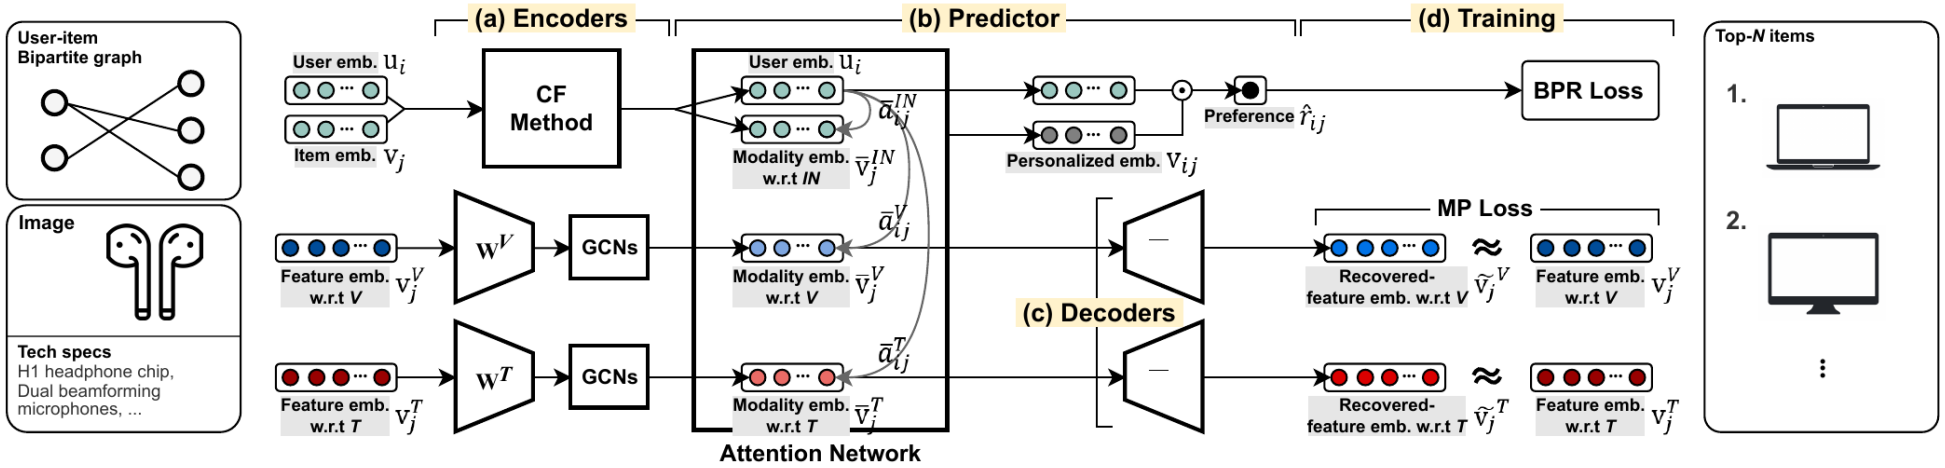
p-유사도	사전학습 특징으로 계산한 상품 간 유사도 (원래 정보)
f-유사도	모델 학습이 끝난 최종 임베딩으로 계산한 유사도
평균 차이	상품마다 두 값의 차이를 평균 → 클수록 고유 정보를 많이 잃음

인기 상품 (38회 초과)	이미지	텍스트	특징
MMGCN	0.66	0.72	거의 모든 상품에서 손실
LATTICE	0.41	0.32	인기 상품에서 손실 급증

이유 인기 상품일수록 많은 사용자 임베딩 쪽으로 끌려감 → "빨간 니트"라는 이미지 정보가 "산 사람들의 평균 취향"으로 덧칠됨

Figure 3, Section 3, Kim et al., CIKM 2022 (p.3–4) · 파랑 = 전체 상품, 빨강 = 인기 상품, 점선 = 평균

3.1 Overview



설정

- 입력: 사용자–상품 상호작용 + 상품 이미지 특징(4,096차원) + 텍스트 특징(1,024차원)
- 모달리티 3개: V (Visual) · T (Textual) · IN (Interaction)
- 목표: 각 사용자가 아직 안 산 상품 중 Top-N 추천

전체 흐름

(a) Encoders	세 모달리티 임베딩(64차원) + 사용자 임베딩
(b) Predictor	어텐션으로 섞은 개인화 임베딩 → 선호 점수
(c) Decoders	이미지·텍스트 임베딩을 원래 크기로 복원
(d) Training	BPR Loss + MP Loss 동시 최소화

Figure 4, Section 4.1, Kim et al., CIKM 2022 (p.4)

3.2 (C1) Encoder: Interaction Modality • Compression Layer

① 상호작용 모달리티 (Interaction Modality)

아무, @모델?+qt ^ @_ A, @Xqt@qA, _ @를 돌려 사용자 임베딩 $\mathbf{u}_i$와 상품의 상호작용 임베딩 $\bar{\mathbf{v}}_j^{IN}$를 얻음 代구매기록도 X하나의 모달리티 X로 취급

② 압축층 (Compression Layer, Eq.1)

$$\bar{\mathbf{v}}_j^m = \mathbf{v}_j^m \mathbf{W}_m, \qquad m \in \{V, T\}$$

- $\mathbf{v}_j^m$ ◥상품 o의 원래 특징 ?이미지 ú¼ Æu 텍스트 ð¼ úú차원@고정 입력
- $\mathbf{W}_m$ ◥학습되는 가중치 행렬 ?d_m 뜷W@
- $\bar{\mathbf{v}}_j^m$ ◥압축된 ùú차원 모달리티 임베딩

비유 4,096칸짜리 설문 응답을 64개 요약 점수로 줄이는 것 — 어떤 칸을 얼마나 섞을지(W)를 학습으로 정함

Eq.(1), Section 4.2, Kim et al., CIKM 2022 (p.5)

3.2 (C1) Encoder: K-NN Item Graph • GCN

LATTICE의 방식을 그대로 차용 — 같은 모달리티에서 닮은 상품끼리 정보를 나눠 임베딩을 보강

① kNN 상품 그래프 (Eq.2–3)

$$A_{jp}^{m} = \begin{cases} s_{jp}^{m}, & v_p \in \mathcal{N}_j^m \\ 0, & \text{otherwise} \end{cases} \qquad \mathbf{G}^m = \lambda \mathbf{A}^m + (1-\lambda)\tilde{\mathbf{A}}^m$$

- s_{jp}^{m} : 두 상품의 코사인 유사도 / $\mathcal{N}_j^m$: 가장 닮은 k개
- $\mathbf{A}^m$: 원래 특징 기준 / $\tilde{\mathbf{A}}^m$: 압축 임베딩 기준
- λ : 얼마나 원래 특징 그래프를 믿을지

② GCN (Graph Convolutional Network, Eq.4)

$$\left(\bar{\mathbf{v}}_j^m\right)^l = \sum_{v_p \in \mathcal{N}_j^m \cup \tilde{\mathcal{N}}_j^m} \bar{g}_{jp}^m \left(\bar{\mathbf{v}}_p^m\right)^{l-1}, \qquad \bar{\mathbf{G}}^m = (\mathbf{D}^m)^{-1/2}\mathbf{G}^m(\mathbf{D}^m)^{-1/2}$$

- 닮은 이웃 상품 임베딩의 가중평균으로 내 임베딩을 보강
- $\mathbf{D}^m$: 차수 행렬 → $\mathbf{D}^{-1/2}$ 정규화로 이웃 많은 상품의 값 폭주 방지

핵심 이 단계까지 이미지·텍스트 임베딩에는 구매기록이 전혀 섞이지 않음 → 뒤의 Late Fusion의 전제

Eq.(2)–(4), Section 4.2, Kim et al., CIKM 2022 (p.5)

ĎĈĎ AĞDÆĬ ÞONJÕ,RØÞĚĨ ØNJŇÕÕRŚĆŇŖ ŇÞO GRROØRÕØØ

(사용자 i, 상품 j) 쌍마다 세 모달리티의 영향력을 따로 계산 · query = 사용자 $\mathbf{u}_i$, key · value = $\bar{\mathbf{v}}_j^V, \bar{\mathbf{v}}_j^T, \bar{\mathbf{v}}_j^{IN}$

$$a_{ij}^m = \frac{\mathbf{u}_i \cdot \bar{\mathbf{v}}_j^m}{\sqrt{d}}, \qquad \bar{a}_{ij}^m = \frac{\exp(a_{ij}^m)}{\sum_{m' \in \{V,T,IN\}} \exp(a_{ij}^{m'})}$$

- a_{ij}^m : 사용자 취향과 상품 j의 모달리티 m이 얼마나 맞는지 (내적)
- √d : 차원이 크면 내적이 커져 한쪽으로 쏠리는 것을 막는 스케일링
- $\bar{a}_{ij}^m$: softmax를 거친 최종 가중치, 세 값의 합 = 1

예시

$(a^V, a^T, a^{IN}) = (2, 0, 1) \xrightarrow{\text{softmax}} (\bar{a}^V, \bar{a}^T, \bar{a}^{IN}) = (0.67, 0.09, 0.24)$ → 이 쌍에서는 디자인 67% · 스펙 9% · 구매기록 24%로 판단

Eq.(5), Section 4.2, Kim et al., CIKM 2022 (p.5)

3.3 (C2) Predictor: Personalized Embedding · Late Fusion

$$\mathbf{v}_{ij} = \sum_{m \in \{V,T,IN\}} \bar{a}_{ij}^{m} \bar{\mathbf{v}}_{j}^{m}$$

$$\hat{r}_{ij} = \mathbf{u}_i \cdot \mathbf{v}_{ij}$$

- $\mathbf{v}_{ij}$ (개인화 임베딩, Eq.6): 같은 상품도 사용자마다 다르게 보이는 상품 벡터
- $\hat{r}_{ij}$ (선호 점수, Eq.7): 사용자 벡터와의 내적 → 높은 순으로 Top-N 추천
- $\bar{a}_{ij}^{m}$로 어떤 모달리티가 이 상호작용에 가장 영향을 줬는지 확인 가능

	이른 융합 ÆgÑÞÓš HŕQŐØØ˝ Ï Ï ÎĦĞÏ Æ	늦은 융합 (Late Fusion · MARIO)
언제 섞나	이미지·텍스트 임베딩을 학습할 때부터 상호작용을 섞음	각자 독립적으로 만든 뒤 Eq.(6)에서만 섞음
결과	이미지 고유 정보가 상호작용 신호로 오염	V · T 임베딩의 고유성 유지
근거	RQ1 항상 최하위 · 고유 정보 손실 최대 (Table 6)	손실 최소 + 최고 성능

키포인트 처음부터 섞으면 이미지·텍스트 임베딩이 상호작용 신호에 맞춰 학습됨 → 마지막에만 합쳐 고유성을 지킴

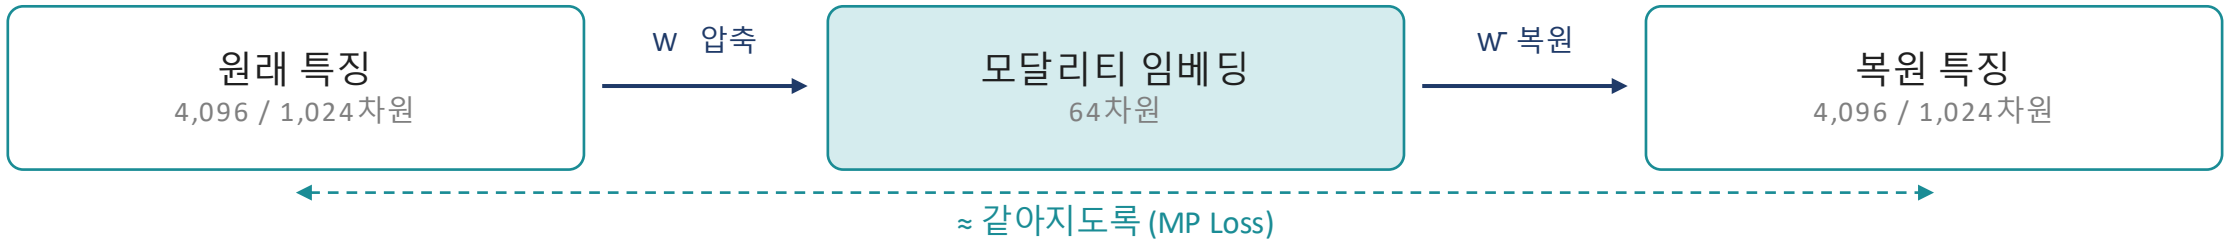
Eq.(6)–(7), Section 4.2, Kim et al., CIKM 2022 (p.5)

3.4 (C3) Decoder for Modality Preservation

압축된 64차원 임베딩을 다시 원래 차원(4,096 / 1,024)으로 늘리는 선형층

$$\tilde{\mathbf{v}}_j^m = \bar{\mathbf{v}}_j^m \tilde{\mathbf{W}}^m, \qquad m \in \{V, T\}$$

- $\mathbf{W}^m$: 학습되는 디코더 가중치 (d × d_m)
- $\tilde{\mathbf{v}}_j^m$: 복원된 특징 → 원래 특징 $\mathbf{v}_j^m$과 비교 (MP Loss)
- 상호작용(IN)은 복원할 "원본 특징"이 없어 디코더 없음



비유 요약본만 보고 원문을 다시 써 보는 시험 — 복원을 잘하려면 요약본에 원문의 핵심이 남아 있어야 함 (Autoencoder와 같은 아이디어)

Eq.(8), Section 4.2, Kim et al., CIKM 2022 (p.5–6)

3.5 Training: BPR Loss + MP Loss

BPR Loss (Eq.9)

$$\mathcal{L}_{BPR} = -\sum_{u_i \in \mathcal{U}} \sum_{v_j \in \mathcal{N}_i} \sum_{v_p \in \mathcal{I} \setminus \mathcal{N}_i} \ln \sigma\left(\hat{r}_{ij} - \hat{r}_{ip}\right)$$

- 산 상품 점수 $\hat{r}_{ij}$ 가 안 산 상품 점수 $\hat{r}_{ip}$ 보다 높을 확률을 최대화 · σ = sigmoid
- 안 산 상품은 무작위로 뽑아 비교 (Negative Sampling)

MP Loss (Eq.10)

$$\mathcal{L}_{MP} = \sum_{m \in \{V,T\}} \sum_{v_j \in \mathcal{I}} \sum_{f=1}^{d_m} \left| \mathbf{v}_j^m(f) - \tilde{\mathbf{v}}_j^m(f) \right|$$

- 원래 특징과 복원 특징의 칸별 차이 절댓값 합 (L1 거리)
- V · T만 대상 · 압축층 W와 디코더 W를 업데이트

Final Loss (Eq.11)

$$\mathcal{L} = \mathcal{L}_{BPR} + \mu \mathcal{L}_{MP}, \qquad \mu \in [0, 1]$$

μ : MP Loss의 비중 (실험에서는 μ = 1)

Eq.(9)–(11), Algorithm 1, Section 4.3, Kim et al., CIKM 2022 (p.6)

4. Evaluation — Questions & Datasets

Research Questions

- RQ1 최신 모델 대비 정확도
- RQ2 이미지·텍스트 둘 다 필요한가
- RQ3 어텐션이 효과적인가
- RQ4 MP Loss가 고유 정보를 지키는가
- RQ5 어떤 CF에 붙여도 좋아지는가

데이터 Amazon 리뷰 4개 카테고리 · 이미지 4,096차원 (deep CNN) / 텍스트 1,024 (Sentence-Transformer)

데이터셋	사용자	상품	상호작용	희소도
Baby	19,445	7,050	160,792	99.88%
Clothing	4,955	5,028	32,363	99.87%
Office	4,874	2,406	52,957	99.55%
Musical	1,429	900	10,261	99.20%

전처리 · 분할 상호작용 5회 미만인 사용자·상품 제거 · 학습 / 검증 / 테스트 = 80 / 10 / 10 (기존 연구 GRCN·MMGCN·LATTICE와 같은 방식)

~ŝŪźŭ▸xŹūgŸóŭ▫ŏ▸Vŷü ŹρŝŭŁ, Ⅳ^ ŭĭĭ ŭŭ ?ŕù 5ĥ@

4. Evaluation — Protocol & Implementation

Top-K 추천 (K = 10, 20) · t-검정(95% 신뢰수준)으로 유의성 확인 (* = p < 0.05)

지표

$$\text{Precision@}K = \frac{|\text{Top}K \cap \text{Test}|}{K}, \qquad \text{Recall@}K = \frac{|\text{Top}K \cap \text{Test}|}{|\text{Test}|}$$

$$\text{DCG@}K = \sum_{k=1}^{K} \frac{rel_k}{\log_2(k+1)}, \qquad \text{NDCG@}K = \frac{\text{DCG@}K}{\text{IDCG@}K}$$

- Precision: 추천한 K개 중 맞은 비율 · Recall: 정답 중 추천에 잡힌 비율
- NDCG: 정답을 위쪽에 놓을수록 높은 점수 (정답이면 rel = 1)

Baselines

구분	방법
CF (상호작용만)	BPRMF, NGCF, LightGCN
멀티미디어	MAML, MMGCN, GRCN, LATTICE

구현 세부

- 임베딩 64차원 (모든 모델 통일) · batch 1024 · learning rate 0.0005 (Baby, Office) / 0.005 (나머지) · 정규화 0.00001
- k = 10, λ = 0.9, μ = 1 · RQ1의 CF는 LightGCN · 경쟁 모델은 저자 코드 + 검증셋 그리드 서치 · NVIDIA V100 ×2

Section 5.1, Kim et al., CIKM 2022 (p.7)

4. RQ1 — Overall Performance

	Baby			Clothing			Office			Musical		
	NDCG	Recall	Pre	NDCG	Recall	Pre	NDCG	Recall	Pre	NDCG	Recall	Pre
MAML	–	–	–	.0226	.0442	.0044	.0505	.0887	**.0112**	.0662	.1302	.0134
MMGCN	.0187	.0370	.0039	.0133	.0260	.0026	.0281	.0534	.0067	.0517	.0980	.0101
GRCN	.0262	.0468	.0050	.0194	.0355	.0036	.0553	.0845	.0106	.0541	.1068	.0110
LATTICE	.0276	.0503	.0053	.0221	.0404	.0040	**.0589**	.0902	.0109	.0769	.1459	.0148
MARIO	**.0300***	**.0539***	**.0056***	**.0259***	**.0484***	**.0048***	.0583	**.0932***	.0110	**.0790***	**.1513***	**.0153***
Improv.	8.58%	7.20%	6.81%	14.61%	9.59%	9.09%	−0.89%	3.38%	−1.47%	2.73%	3.68%	3.30%

대부분 1위

최강 경쟁자

Clothing NDCG@10 · 최강 경쟁자 MAML 대비 대비 (.0259 vs .0226)

예외: Office

亚◦åÁ于

NDCG@10은 LATTICE(.0589), Pre@10은 MAML(.0112)에 근소하게 뒤짐 · * 없음

Early Fusion의 한계

항상 최하위

MMGCN은 모든 데이터·지표에서 꼴찌 → 정보 보존이 중요

~ŝŪźū?\ŏī @Vŷ Źǫŝv▸, IV^ ŭī ŭŭ ??»n@=굵게 交ŏ위▸밑줄 交ŭ위▸O交?产 ◦ī ů▸亚交메모리 부족 =\ŭī 도 같은 경향

4. RQ2 • RQ3 — Modality & Attention Ablation

RQ2 모달리티 제거 (Table 4)

< O Ÿ² ◥이미지 임베딩 제거
< O Ÿ ~◥텍스트 임베딩 제거

모델	NDCG@10	Recall@10	Pre@10
MARIO w/o V	.0233	.0415	.0042
MARIO w/o T	.0243	.0460	.0046
MARIO	**.0259**	**.0484**	**.0048**

- 둘 다 필요 · NDCG@10 기준 w/o V 대비 +11.38%, w/o T 대비 +6.51%
- Clothing에선 이미지 유사도가 상호작용과 가장 달라 "새 정보"가 많음

RQ3 결합 방식 (Table 5)

- mean / max: 평균 · 최대 풀링
- fc: 세 임베딩을 이어붙여 완전연결층에 입력

모델	NDCG@10	Recall@10	Pre@10
MARIO mean	.0256	.0478	.0048
MARIO max	.0232	.0429	.0043
MARIO fc	.0117	.0214	.0022
MARIO	**.0259**	**.0484**	**.0048**

Table 4, Table 5 (Clothing), Kim et al., CIKM 2022 (p.8) · 다른 데이터셋 결과는 저자 웹사이트에만 공개

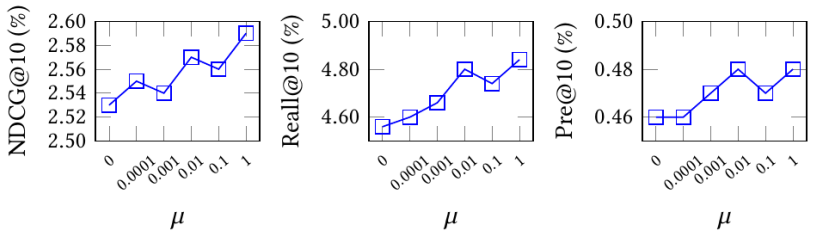
4. RQ4 — Modality Preservation

RQ4-1 고유 정보 보존 정도 (Table 6)

	모달리티	MMGCN	LATTICE	MARIO
전체 상품	Visual	0.6111	0.2721	**0.2668**
	Textual	0.6541	0.1961	**0.1842**
인기 상품	Visual	0.6576	0.4075	**0.3062**
	Textual	0.7221	0.3155	**0.2739**

- 값 = p-유사도와 f-유사도의 평균 차이 (작을수록 잘 보존)
- 항상 MARIO가 최소 · 인기 상품의 이미지에서 0.41 → 0.31로 가장 크게 개선
- Early Fusion(MMGCN)은 손실이 2배 이상

RQ4-2 μ (MP Loss 비중)의 영향 (Figure 6)

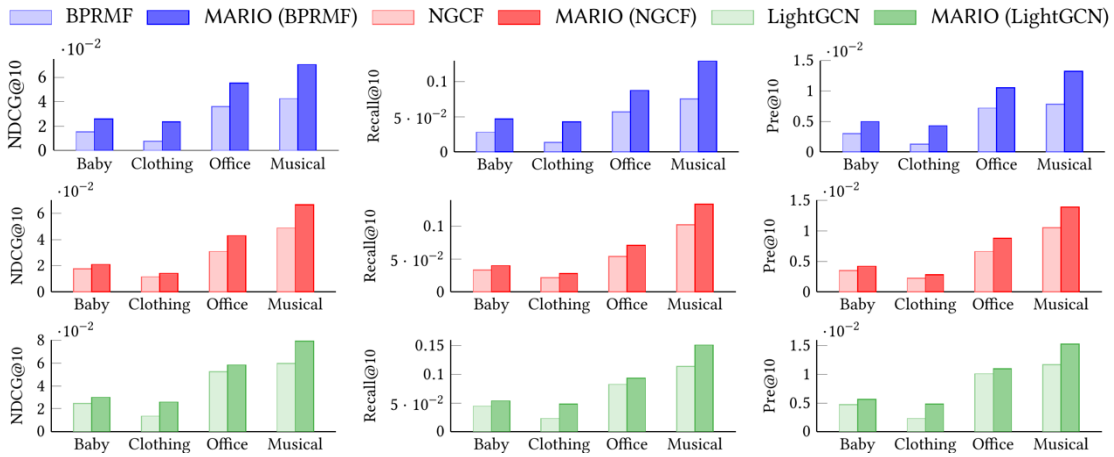


- μ = 0 (MP Loss 없음)일 때 항상 최저
- μ = 1일 때 NDCG@10 +2.31%, Precision·Recall@10 +6.19%
- 단, 탐색 범위가 (0, 1]뿐 → 1보다 큰 μ는 미확인

시사점 MP Loss는 상호작용으로 잡기 어려운 모달리티(여기선 이미지)에서 더 효과적

Table 6, Figure 6 (Clothing), Kim et al., CIKM 2022 (p.8–9)

4. RQ5 — Plug-in to Any CF Method



Clothing NDCG@10 향상

MARIO (BPRMF) vs BPRMF	+215.57%
MARIO (NGCF) vs NGCF	+23.45%
MARIO (LightGCN) vs	+92.52%

- 연한 막대 = 원래 CF, 진한 막대 = MARIO를 얹은 버전 → 모든 데이터·지표에서 향상
- 세 버전 중 MARIO (LightGCN)이 항상 최고 → 더 좋은 CF가 나오면 MARIO도 함께 좋아짐

Behind 상호작용 모달리티를 CF에 맡긴 설계(C1) 덕분에 CF만 갈아 끼우면 됨

Figure 5, Section 5.2, Kim et al., CIKM 2022 (p.9)

5. Related Work

분류	대표 연구	한계
단일 모달리티	VBPR (이미지), CTRank (텍스트)	이미지와 텍스트를 동시에 쓰지 못함
다중 · 그래프	MMGCN, GRCN	Early Fusion 또는 사용자 단위 영향력
다중 · 상품 관계	LATTICE	전역 영향력 · 인기 상품의 고유 정보 손실
다중 · 기타	JRL, MAML	쌍 단위 영향력 · 고유 정보 보존을 다루지 않음

LATTICE와의 차이

- kNN 상품 그래프 · GCN은 그대로 차용
- 영향력: 전역 → 쌍 단위 어텐션
- 고유 정보 보존용 디코더 · MP Loss 추가

MMGCN과의 차이

- 이른 융합 → 늦은 융합
- 모달리티별 사용자–상품 그래프 대신 상품–상품 그래프
- 상호작용 부분을 임의 CF로 교체 가능

MARIO 쌍 단위 모달리티 어텐션 + 디코더로 고유 정보 보존 + 어떤 CF에도 붙는 플러그인 구조

Section 2, Kim et al., CIKM 2022 (p.2)

6. Conclusion

관찰	기존 멀티미디어 추천은 ① 쌍 단위 모달리티 영향력을 보지 못하고 ② 학습 중 모달리티 고유 특성을 잃음
방법	Modality-aware Attention으로 쌍마다 모달리티를 섞고(C2), Modality-preserving Decoder + MP Loss로 고유 Loss로 고유 정보를 보존(C3)
결과	4개 데이터셋 · 7개 경쟁 모델 대비 대부분 1위 · 고유 정보 손실 최소 · 어떤 CF에 붙여도 성능 향상

한 줄 요약 이미지 · 텍스트 · 구매기록의 고유 정보를 각자 지키면서, (사용자, 상품) 쌍마다 다르게 섞어 추천하는 모델

Thank you

Q&A

Presented by Minsung Park

